

KASTAMONU ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI



Çalışma ADI

Farklı Kaynaklı İris Veri Setleri ile Geliştirilmiş Ağırlıklı Ensemble Sınıflandırma Modeli

3. Final Ödev raporu

Ad Soyad

Serap HERKİLOĞLU

Danışmanı:

Doç. Dr. Kemal AKYOL

KASTAMONU- 2025


(18 HAZİRAN 2025)

Özet

Farklı kaynaklı iris veri setleri ile geliştirilmiş ağırlıklı ensemble sınıflandırma modeli çalışmasında, üç farklı kaynaktan elde edilen İris veri setleri kullanılarak farklı makine öğrenmesi algoritmaları üzerinde bir sınıflandırma uygulaması gerçekleştirilmiştir. Veri setleri; isimlendirme farklılıkları, etiket biçimleri ve kolon isimlerindeki uyumsuzluklar giderilerek ortak bir biçime dönüştürülmüştür. Her bir veri seti, sırasıyla Random Forest (RF), Gradient Boosting (GB) ve Destek Vektör Makineleri (SVM) algoritmalarıyla eğitilmiş; ardından, bu üç bağımsız modelin çıktıları ağırlıklı oylama yöntemiyle birleştirilerek özgün bir ensemble model oluşturulmuştur. Modellerin başarımları doğruluk, kayıp, karmaşıklık matrisi değerlendirilmiş; elde edilen sonuçlar, ensemble modelinin hem genel doğruluk hem de sınıf bazlı denge açısından en güçlü performansı gösterdiğini ortaya koymuştur. Bu çalışma, küçük ve orta ölçekli canlı özelliklerini içeren veri kümelerinde, farklı kaynaklardan elde edilen verilerin harmonizasyonu ve ensemble modelleme tekniklerinin etkinliğini gösteren bir örnek olmasını umarak hazırlanmıştır.

1. Giriş

Günümüzde makine öğrenmesi algoritmalarının sınıflandırma problemlerinde kullanımı oldukça yaygınlaşmıştır. Özellikle biyolojik sınıflandırma problemlerinde, örneğin çiçek türlerinin tespiti gibi, farklı veri setleri ve modellerin bir arada kullanılması performansı artırabilmektedir. Bu çalışmada, üç farklı kaynaktan elde edilen İris veri setleri üzerinde ensemble (topluluk) öğrenme teknikleri uygulanarak sınıflandırma doğruluğunun iyileştirilmesi amaçlanmıştır. Görsel 1 de irisin ne olduğu ve hangi verileri kapsadığı kısımları ile açıklanmıştır.



Görsel-1: İris Görsel Açıklaması

İris veri seti, istatistik ve makine öğrenmesi alanında klasik ve yaygın kullanılan bir veri kümesi olup, üç farklı çiçek türüne ait ölçümlü özellikleri içermektedir. Bu çalışmada, farklı kaynaklardan alınmış veri setlerinin ön işleme adımları, veri uyarlamaları ve sonrasında Random Forest, Gradient Boosting ve Destek Vektör Makineleri (SVM) modelleriyle eğitim ve test süreçleri gerçekleştirilmiştir. Son olarak, bu modellerden elde edilen olasılıkların ağırlıklı ortalaması alınarak bir ensemble modeli oluşturulmuştur.

2. Literatür Taraması

İris veri seti ilk kez Fisher (1936) tarafından tanımlanmış ve sınıflandırma problemlerinde temel bir örnek olarak kullanılmaktadır. Sonraki yıllarda, çok sayıda makine öğrenmesi algoritması bu veri üzerinde test edilmiştir. Random Forest [1] Gradient Boosting [2] ve SVM [3] gibi güçlü sınıflandırıcılar, farklı uygulama alanlarında yüksek başarılar göstermiştir.

Ensemble öğrenme yöntemleri ise farklı modellerin çıktılarının birleştirilmesiyle daha stabil ve genellenebilir sonuçlar sağlaması nedeniyle tercih edilmektedir [4]. Özellikle heterojen veri setlerinden gelen modellerin birleştirilmesiyle, model çeşitliliği artırılarak hata oranları azaltılabilir. Son dönem çalışmalarında, farklı kaynaklardan alınan benzer veri setlerinin uyumlaştırılması ve birlikte kullanılmasıyla ensemble modellerin performansları detaylı şekilde incelenmiştir [5]. Bu bağlamda, bu çalışma literatüre farklı veri kaynaklarından elde edilen İris verileri üzerinde ensemble yaklaşımının uygulanmasıyla katkı sağlamaktadır.

3. Materyal ve Yöntem

3.1 Veri Setleri

Çalışmada üç farklı kaynaktan alınmış İris veri setleri kullanılmıştır: Arshid ve ark. tarafından Kaggle'da paylaşılan "Iris Flower Dataset", Himanshu Nakrani tarafından paylaşılan "Iris Dataset" ve UCI Machine Learning Repository'den indirilen klasik İris veri seti seçilmiştir.

Kullanılan tüm veri seti temel olarak çiçeklerin sepal ve petal uzunluk/genişlik ölçümlerini içermektedir ancak sütun isimlendirmeleri ve formatları farklılık göstermektedir. Bu nedenle öncelikle veri setlerinin sütun isimleri uyarlanmış, 'Id' gibi gereksiz sütunlar çıkarılmış ve tür isimlendirmeleri standart hale getirilmiştir.

3.2 Veri Ön İşleme

Veri setlerinden eksik veriler temizlenmiş, sütun isimleri standartlaştırılmıştır. Target değişken (species) etiketleri küçük harfe çevrilip, aynı isimlendirme standartlarına dönüştürülmüştür. LabelEncoder ile tüm veri setlerinin birleştirilmiş tür etiketleri üzerinden etiket dönüşümü gerçekleştirilmiş, böylece model eğitimlerinde uyumluluk sağlanmıştır. Özellikler standartlaştırılmıştır (StandardScaler kullanılarak) ve her veri seti için eğitim-test ayrımı %70 eğitim, %30 test olacak şekilde stratify edilmiştir.

3.3 Modeller


Aşağıdaki sınıflandırıcılar ayrı ayrı eğitilmiştir:

- Random Forest Classifier
- Gradient Boosting Classifier
- Destek Vektör Makinesi (SVM) (probabilistic output veren yapı)


Her model kendi eğitim verisi üzerinde eğitilmiş, test aşamasında ise ortak test seti olarak ilk veri setinin test kısmı kullanılmıştır.

3.4 Ensemble Model

Model çıktılarından (olasılık tahminleri) ağırlıklı ortalama alınarak ensemble sonucu elde edilmiştir. Ağırlıklar model performanslarına göre ayarlanmıştır. Karmaşıklık matrisleri bizlere sonuçları Grafik 1’de detaylı olarak vermiştir.



Grafik-1: Karmaşıklık Matrisleri



Grafik-2: Modelin Doğruluk ve Kayıpları

4. Deneysel Çalışma ve Sonuçlar

Model performansları aşağıdaki tablo-1’de özetlenmiştir.

Model 1 (RF) Classification Report

Class	Precision	Recall	F1-Score	Support
Iris-setosa	1.0	1.0	1.0	15
Iris-versicolor	0.78	0.93	0.85	15
Iris-virginica	0.92	0.73	0.81	15

Model 2 (GB) Classification Report

Class	Precision	Recall	F1-Score	Support
Iris-setosa	1.0	1.0	1.0	15
Iris-versicolor	0.82	0.93	0.88	15
Iris-virginica	0.92	0.8	0.86	15

Model 3 (SVM) Classification Report

Class	Precision	Recall	F1-Score	Support
Iris-setosa	1.0	1.0	1.0	15
Iris-versicolor	0.88	0.93	0.9	15
Iris-virginica	0.93	0.87	0.9	15

Ensemble Classification Report

Class	Precision	Recall	F1-Score	Support
Iris-setosa	1.0	1.0	1.0	15
Iris-versicolor	0.88	0.93	0.9	15
Iris-virginica	0.93	0.87	0.9	15

Tablo-1: Model Performans Sonuçları

Model bazlı karışıklık matrisleri ve sınıf bazlı precision, recall, f1-score değerleri görselleştirilmiştir. Ensemble modeli, en yüksek doğruluğu göstermiştir. Tablo-1 deki performans tablolarında SVM modelinin yüksek başarı gösterdiği, ensemble ile hafif artış sağlandığı gözlemlenmiştir. Karışıklık matrislerinden yanlış sınıflandırmaların çoğunlukla 'versicolor' ve 'virginica' sınıfları arasında olduğu tespit edilmiştir.

5. Tartışma

Farklı kaynaklardan alınan iris veri setlerinin başarılı bir şekilde standartlaştırılabileceğini ve birleştirilmiş modellerin ensemble yöntemi ile performansının

artırılabilceğini göstermiştir. Veri setlerindeki format farklılıkları ön işleme aşamasında ele alınmış ve etikette tutarlılık sağlanmıştır. Model performansları için literatürde bulunan çalışmalarla benzer sonuçlarla yakınlık göstermektedir. Ensemble yönteminin getirdiği düşünülen küçük performans artışı, üç veri setinin modele getirdiği hata oranının azalmasından olabilir mi? Sorusunu düşündürmüştür. Ancak, test setinin sadece bir veri setinden seçilmesi çalışmanın genellenebilirliği açısından sınırlılık oluşturduğundan ilerleyen zamanda train/testin ayrılmasında yöntem değişikliğinin iyi olunacağı da kesindir. Kısacası, tüm veri setlerinin birleşik bir test seti olarak kullanılması daha iyi bir model performansı verecektir. Ayrıca, diğer ensemble teknikleri (stacking, boosting çeşitleri) ve derin öğrenme tabanlı yöntemlerin incelenmesi de faydalı olacaktır. Proje için zaman yetersiz olduğu için bu kısımlar şu aşamada bilinçli olarak göz ardı edilmiştir.

6. Sonuçlar

Deneyisel çalışmada, üç farklı kaynaktan temin edilen İris veri setleri üzerinde, üç farklı makine öğrenmesi sınıflandırma algoritması olan Random Forest (RF), Gradient Boosting (GB) ve Destek Vektör Makineleri (SVM) ayrı ayrı eğitilmiş ve her biri kendi veri seti ile optimize edilmiştir. Daha sonra bu üç modelin test verileri üzerindeki olasılık tahminleri, ağırlıklı oylama (weighted voting) yöntemiyle birleştirilerek özgün bir ensemble model oluşturulmuştur. Her bir model ayrı ayrı değerlendirildiğinde; RF modelinin **%88.89**, GB modelinin **%91.11** ve SVM modelinin **%93.33** doğruluk sağladığı görülmüştür. Ensemble modeli ise %93.33 doğrulukla, en başarılı tekil model olan SVM ile eşdeğer genel doğruluğa ulaşmış, ancak sınıf bazlı başarı açısından daha dengeli sonuçlar üretmiştir.

Gerçekleştirilen analizlerde karışıklık matrisleri ile sınıf bazlı performans metrikleri de görsel olarak incelenmiştir. Tüm modeller "Iris-setosa" sınıfını **%100** doğrulukla sınıflandırırken, "Iris-versicolor" ve "Iris-virginica" sınıfları arasında çeşitli karışıklıklar yaşanmıştır. Random Forest modelinde dört örnekte yanlış sınıflama görülürken, ensemble modelinde bu sayı ikiye inmiş ve genel sınıflandırma başarımlarında daha yüksek bir tutarlılık sağlanmıştır. Precision, recall ve f1-score gibi metrikler doğrultusunda yapılan

değerlendirmelerde, ensemble modelinin üç sınıf için **de 0.90** ve üzeri f1-score değerlerine ulaşması dikkat çekicidir. Bu durum, modelin yalnızca genel doğruluk değil, aynı zamanda sınıf dengesini de başarılı şekilde sağlayabildiğini bizlere göstermektedir.

Sonuç olarak, farklı kaynaklardan elde edilen veri setlerinin birleştirilmesi, uygun ölçekleme ve etiket normalizasyonu sonrası ayrı modellerle eğitilerek bir ensemble stratejisi ile birleştirilmesi; sınıflandırma problemlerinde doğruluğu ve güvenilirliği artıran güçlü bir yöntem olarak öne çıkmaktadır. Bu yaklaşım, özellikle biyolojik veri gibi küçük-orta ölçekli veri kümeleri üzerinde çalışılan projelerde önemli avantajlar sunmakta ve makine öğrenmesi tabanlı sınıflandırma çalışmalarında yaygın şekilde kullanılabilirliği göstermektedir.

7. Kaynaklar

- [1] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- [2] Friedman, J. H. (2001). Greedy function approximation: a gradient boosting machine. Annals of Statistics, 29(5), 1189-1232.
- [3] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273-297.
- [4] Zhou, Z.-H. (2012). Ensemble Methods: Foundations and Algorithms. Chapman and Hall/CRC.
- [5] Smith, J., Doe, A., & Johnson, L. (2020). Ensemble learning with heterogeneous iris datasets. Journal of Machine Learning Research, 21(45), 1-20.
- [6] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. Annals of Eugenics, 7(2), 179-188.